Compte rendu — Optimiser un réseau de neurones

TP « Optimiser votre réseau » · 19 octobre 2026

1. Contexte et méthode

Classification de textes en 4 classes : TF-IDF (2 000 mots) puis réseau dense Keras à deux couches cachées. Le corpus est petit : environ 124 textes d'apprentissage, 31 de validation et 52 de test. Un texte pèse donc 3,2 points de précision, et la marge d'incertitude sur la validation est d'environ ±0,14 ($1{,}96 \cdot \sqrt{p(1-p)/n}$, avec p = 0,8 et n = 31). Les réglages sont comparés sur la validation ; le test n'est utilisé qu'à la fin.

2. Tableau de synthèse

Version du modèle	Précision	Taille / paramètres	Commentaire (gain réel ou bruit ?)
Réseau de départ (64/32, taux 0,001)	0,935 (validation)	130 276 paramètres (≈ 509 Ko)	Point de départ. Sur 5 graines : 0,903 ± 0,029, donc 0,935 est le haut de la fourchette.
Meilleur taux d'apprentissage (0,001)	0,935	130 276 paramètres	Gain réel face aux autres taux (0,581 / 0,742 / 0,613 ; écarts ⩾ 0,19, au-dessus de la marge). Aucun gain face au départ, qui utilise déjà ce taux.
Avec dropout (0,5)	0,935	545 668 paramètres (256/128)	Perte de validation 0,272 → 0,235, mais précision −0,033 (1 texte) par rapport au réseau sans remède (0,968). Gain non démontré.
Avec arrêt précoce	0,968	545 668 paramètres (256/128)	Résultat identique au réseau sans remède : l'arrêt ne s'est jamais déclenché (100 epochs effectués). Aucun effet.

Version du modèle	Précision	Taille / paramètres	Commentaire (gain réel ou bruit ?)
Quantifié (64/32)	[à relever sur le test]	≈ 131 Ko attendus (509 Ko ÷ 4) [à relever]	Poids ÷ 4 sans changer l'architecture. La précision doit rester proche de celle de l'original.
Petit réseau (8/4)	0,484 (validation)	16 064 paramètres (≈ 63 Ko)	Taille ÷ 8, mais précision −0,45, très au-dessus de la marge : perte réelle.

3. Interprétation des résultats

Ce qui dépasse le bruit. Le taux 0,001 est nettement le meilleur. Trop petit (0,0001), le réseau n'a probablement pas fini d'apprendre en 30 epochs ; trop grand (0,1), ses pas sautent par-dessus la solution. Côté taille, passer de 4/2 (0,387) à 16/8 (0,806) est un gain réel (+0,419), et le réseau 8/4 perd environ la moitié de la précision du 64/32.

Ce qui ne prouve rien. Les écarts 16/8 → 64/32 (+0,129) et 64/32 → 256/128 (+0,033) restent sous la marge de 0,14. Le 256/128 coûte 4,2 fois plus de paramètres pour un texte de mieux sur 31. Les 5 graines (0,903 ; 0,871 ; 0,935 ; 0,871 ; 0,935) donnent un écart-type de 0,029 : un écart de 0,5 point entre deux réglages est très inférieur à cette dispersion, on ne peut pas dire que l'un est meilleur.

Surapprentissage. Il n'a pas été observé : la perte de validation minimale (0,272) est égale à la finale, elle ne remonte donc pas. Le jeu d'apprentissage ne compte qu'environ 124 textes, si bien que `n_exemples = 200` les utilise tous et n'a rien changé. Sans remontée de la perte, l'arrêt précoce n'a rien à arrêter. Le dropout est le seul remède qui baisse la perte (−0,037) : un remède ne réduit donc pas toujours la perte, et perte et précision peuvent évoluer différemment.

Alléger le modèle. La quantification (poids 32 bits → 8 bits entiers) divise la taille par 4 en gardant l'architecture. Réduire le réseau divise la taille par 8 mais fait chuter la précision de moitié. La quantification est donc la voie la moins coûteuse en précision.

4. Conclusion

Je retiendrais le réseau 64/32 avec un taux de 0,001, sans dropout, éventuellement quantifié : environ 0,90 à 0,94 de précision en validation pour ≈ 130 000 paramètres. Le 256/128 n'est pas justifié (gain dans le bruit, 4 fois plus lourd) et le 8/4 est trop imprécis.

Limite principale : avec 31 textes de validation, toute différence fine reste invisible ; il faudrait plus de données et plusieurs graines pour trancher.